Stoa Quiz, Français (Canada) - Questions et réponses

1. Quelle configuration est approuvée?
Réponse : GAIA PREFERENCE · un univers V2 au choix · Hatch RM Style Task - current version

2. Rédige le prompt de 2 à 4 phrases que Megan devrait soumettre.
Réponse : J'ai vu dans le dernier courriel de Priya que le club de lecture est déplacé au vendredi 29 à 19 h, chez elle. Par contre, j'ai le dentiste vendredi de 18 h 30 à 19 h 30, fait que je vais arriver un peu en retard. Peux-tu me préparer un brouillon de réponse à Priya dans Gmail pour l'avertir? Ne l'envoie pas, je veux le relire avant.

3. Quelle demande l'assistant peut-il vraiment réaliser?
Réponse : Lis la conversation du groupe de rando et confirme à Claire dans notre conversation.

4. Quel prompt convient à cet environnement?
Réponse : Vérifie la météo de samedi pour la collecte et rédige une réponse au courriel de l'organisateur.

5. Quelle demande ne porte que sur des actions possibles?
Réponse : Parcours mes Photos, mets la lumière de ma chambre à 30 %, ajoute une entrée dans Nutrition et résume mes Health Records dans une nouvelle page Notion.

6. Quelle lecture de la demande d'Owen est la bonne?
Réponse : Compare les lignes du 15 et du 16 mars. Crée le rappel seulement si la ligne du 16 mars est plus courte de 60 minutes ou plus.

7. Quelle requête donne du vrai travail à l'assistant?
Réponse : Compare mes dépenses d'avril avec mon suivi de budget, ajoute ce qui manque et résume-moi ce qui a changé.

8. Que faut-il faire avec cette paire?
Réponse : Ne pas l'évaluer. Les bras ont reçu des turns différents : passe ou recrée la tâche.

9. Quel énoncé est exact?
Réponse : A compte parce qu'il s'est rétabli. B ne l'a jamais fait : la paire doit être recréée, pas évaluée.

10. Cette évaluation peut-elle passer telle quelle?
Réponse : Non. Des réponses vraiment identiques exigent huit 3 et un Tie; « coulait mieux » ne montre rien.

11. Quelle est la bonne issue?
Réponse : La refuser et recréer la tâche. Les réponses soumises ne sont pas la vraie sortie complète.

12. Qu'est-ce qui va dans Apps utilized?
Réponse : Gmail, Google Calendar et Notion : chaque application vraiment utilisée par l'un des bras.

13. Quelle issue est la bonne?
Réponse : Refuser et recréer. Le 8 avril est passé et le 2 mai est après le 30 avril : B s'est trompé.

14. Quelle préférence globale est la mieux calibrée?
Réponse : A significantly better. Il a fait les deux actions qu'il avait proposées, et l'utilisateur a répondu « Exact. »

15. Quelle évaluation reflète le mieux ce compromis?
Réponse : A significantly better · Style and behavior 5, Correctness 1, Style 5, Coherence & writing quality 4, Helpfulness 1, Completeness 1, Tone 5, Warmth 4

16. Qu'est-ce qui ne va pas dans cette évaluation?
Réponse : Elle ne nomme aucune différence visible entre A et B : les pointages hors Tie sont sans appui.

17. Quels pointages sont justifiés?

Réponse : Correctness (Exactitude) favorise B, et les sept autres dimensions, Warmth compris, sont à 3.

18. Le mot « léger » contredit-il la préférence?
Réponse : Non. Il décrit le petit avantage de forme de A; c'est l'envoi qui décide au global.

19. Quel cas contient une inversion d'action du même bras?
Réponse : Le cas 1 seulement

20. Quel raisonnement est valide pour Completeness?
Réponse : B gagne Completeness, car son texte en plus contient le deuxième événement et ses dates.

21. Est-ce une paire valide, et cette évaluation peut-elle passer?
Réponse : Oui. Un bras peut trouver ce que l'autre rate, et chaque pointage nomme une différence visible.

22. Quels pointages soumis contredisent directement la justification?
Réponse : Coherence & writing quality, Helpfulness et Completeness

23. Quel est le problème exact de cette affirmation?
Réponse : Les deux bras donnent les mêmes dosages, donc ça ne peut pas valoir un avantage en Completeness à B.

24. Cette justification peut-elle passer telle qu'elle est écrite?
Réponse : Non. A liste bien le 27 août : l'affirmation est fausse, même si B est plus détaillée.

25. Quelle description décrit le mieux l'erreur?
Réponse : Une inversion d'action du même bras : A rapporte un fichier HTML, pas un PowerPoint.

26. Quelle est la meilleure issue pour cette évaluation?
Réponse : Refuser telle quelle. B peut encore gagner, mais A rapporte 3 repas, pas 4.

27. Quelles sont les deux affirmations non appuyées dans la justification?
Réponse : La liste revient au 7 juil., et une recherche juillet-août ne peut pas couvrir décembre.

28. Cette évaluation peut-elle passer?
Réponse : Non. « Cette fin de semaine », à partir du 20 août, ne peut pas être en janvier, et pourtant B est dite exacte.

29. Quelle dimension cette différence devrait-elle faire pencher vers B?
Réponse : Style, parce que la formule d'ouverture, le personnage forcé et la question de fin sonnent robot.

30. Où se situe la différence entre A et B?
Réponse : Tone seulement. L'humeur enjouée de B ne convient pas à quelqu'un en deuil.

31. Quels pointages de Style, Tone et Warmth conviennent à cette paire?
Réponse : Style 3 · Tone 3 · Warmth 4

32. Quel ensemble est le mieux calibré?
Réponse : A significantly better · Style and behavior 5 · Correctness 1 · Style 5 · Coherence 5 · Helpfulness 1 · Completeness 1 · Tone 4 · Warmth 4

33. Rédige seulement la Required rationale (4 à 7 phrases, sans chiffres).
Réponse : A est nettement meilleure parce qu'elle a fait la vraie tâche : un brouillon Gmail non envoyé au propriétaire qui demande si « l'augmentation du 1er juin s'applique avant ton renouvellement du 31 août », avec les bonnes dates du bail. B n'a créé aucun brouillon, donne seulement un texte dans la conversation et dit que le bail se termine le « 30 août », ce qui est faux, donc A gagne nettement en exactitude, en utilité et en exhaustivité. Par contre, B gagne nettement en style, en style et comportement et en cohérence, parce que A se lit comme un journal de machine avec des identifiants bruts comme « r-88412 » et une étape de vérification répétée, alors que B sonne comme une vraie personne. B est aussi légèrement meilleure en ton et en chaleur, puisque « Bonne idée de vérifier ça » convient mieux à une petite question du quotidien que « Statut : terminé ». Malgré ces avantages de B, A reste préférée, car faire le brouillon demandé avec les bonnes dates compte

plus ici qu'une voix amicale. A est bonne mais pas parfaite, parce que son journal d'état et ses identifiants bruts rendent la réponse difficile à lire.

34. Quel fait, à lui seul, a décidé ta préférence globale, et pourquoi?

Réponse : Ce qui a décidé, c'est que A a créé le vrai brouillon Gmail non envoyé avec les bonnes dates, alors que B n'a fait aucun brouillon et s'est trompée sur la date du bail. L'utilisateur voulait un brouillon à relire, donc une réponse plus agréable ne peut pas compenser une tâche ratée et une date fausse.

35. L'évaluation soumise est-elle valide?

Réponse : Non. Une IA externe a aidé à écrire la justification soumise.

36. Quelle est la réparation exigée?

Réponse : Recréer la comparaison dans Hatch et écrire la justification soi-même.

37. Comment vérifies-tu les dates et les comptes avant de soumettre une tâche?

Réponse : Avant de soumettre, je compare chaque date avec la date simulée de la tâche et avec la source dans Apps, et je compte moi-même les éléments dans les données et les traces au lieu de croire ce que le bras affirme. Ensuite, je relis la justification pour m'assurer que chaque date, chaque compte et chaque fichier correspond à ce que le bras montre vraiment.

38. Quelle erreur d'évaluation est la plus facile à commettre sans s'en rendre compte, et pourquoi?

Réponse : L'erreur la plus facile à manquer, c'est un pointage dans le mauvais sens : sur l'échelle de 1 à 5, un 2 favorise A et un 4 favorise B, donc un seul mauvais clic peut inverser une dimension alors que la justification semble correcte. On ne l'attrape qu'en vérifiant chaque pointage avec sa phrase dans la justification.